

Fiche Projet - Désagrégation de consommation électrique (NILM)

Le problème

Un compteur électrique intelligent mesure la consommation totale d'un foyer - une seule valeur agrégée, toutes les 30 minutes pour un Linky standard. Derrière ce signal unique se cachent des dizaines d'appareils qui s'allument et s'éteignent de façon simultanée et indépendante.

Le NILM - **Non-Intrusive Load Monitoring** - est le problème inverse : **reconstituer la consommation individuelle de chaque appareil depuis le seul signal agrégé du compteur**, sans installer de capteur supplémentaire dans le logement.

C'est un problème de **séparation aveugle de sources** : on observe $y(t) = \sum_i x_i(t)$ et on cherche à retrouver chaque $x_i(t)$. Le problème est mal posé - il y a une infinité de décompositions possibles. Ce qui le rend tractable, c'est que chaque appareil a une signature électrique caractéristique et des patterns d'usage relativement réguliers.

L'enjeu opérationnel est la **flexibilité énergétique** : identifier quels appareils dans quels foyers peuvent décaler leur consommation aux heures creuses, sans impacter le confort des occupants. C'est une brique essentielle pour la gestion de la demande dans les réseaux électriques avec forte pénétration d'énergies renouvelables intermittentes.

Ce que le projet demande

- Prendre en main les datasets NILM de référence et comprendre leur structure
- Implémenter et comparer plusieurs approches de désagrégation
- Évaluer rigoureusement les modèles avec un protocole inter-foyers
- Construire un indicateur de flexibilité énergétique à partir des sorties du modèle
- Questionner la robustesse des résultats selon la résolution temporelle disponible

Il n'y a pas de solution dominante dans la littérature. Les comparaisons publiées sont souvent faites sur des protocoles incompatibles - c'est une des faiblesses du domaine, et une opportunité pour produire une évaluation rigoureuse.

Données - Datasets NILM de référence

Datasets principaux

UK-DALE (UK Domestic Appliance-Level Electricity) 5 maisons britanniques. Signal agrégé à 1/6 Hz et sous-compteurs par appareil à 16 kHz. Plusieurs années de données. Un des datasets les plus utilisés dans la littérature NILM. → <https://jack-kelly.com/data> → Paper de référence : Kelly & Knottenbelt (2015)

<https://drive.google.com/drive/folders/1XcsqaDY08tjIYxid5gmGSqLDu7HNcXVO?usp=sharing>

Datasets : <https://ukerc.rl.ac.uk/cgi-bin/dataDiscover.pl?Action=detail&dataid=7d78f943-f9fe-413b-af52-1816f9d968b0>

https://data.ceda.ac.uk/edc/d1/7d78f943-f9fe-413b-af52-1816f9d968b0/data/version_0

REFIT (Cleaned UK Household Electricity Demand Dataset) 20 maisons britanniques. Résolution 8 secondes. Sous-compteurs par appareil. Bonne couverture de la diversité des usages résidentiels. → <https://www.refitsmarthomes.org/datasets> → <https://doi.org/10.1038/sdata.2016.122>

Dataset: <https://pureportal.strath.ac.uk/en/datasets/refit-electrical-load-measurements-cleaned-2/datasets/>

(! en csv, pas .h5) : <https://zenodo.org/records/5063428>

REDD (Reference Energy Disaggregation Dataset) 6 maisons américaines. Résolution 1 Hz sur le signal agrégé, 3 Hz sur les sous-circuits. Premier dataset de référence historique du domaine - indispensable pour situer les travaux. → <http://redd.csail.mit.edu> → Paper fondateur : Kolter & Johnson (2011) - <http://redd.csail.mit.edu/kolter-kddsust11.pdf>

Dataset : <https://zenodo.org/records/13917372/files/redd.h5>

ECO Dataset 6 maisons suisses. Résolution 1 Hz. Données d'occupation du logement et météo associées - utile si vous souhaitez intégrer des variables contextuelles. → <https://vs.inf.ethz.ch/res/show.html?what=eco-data>

IAWE (Indian Dataset for Ambient Water and Electricity) 3 maisons indiennes. Utile pour tester la robustesse inter-culturelle et inter-climatique des modèles. → <https://iawe.github.io>

Dataset : <https://zenodo.org/records/13917372/files/iawe.h5>

ENERTALK Dataset 22 maisons coréennes, sous-compteurs à 15 Hz. Résolution plus fine, utile pour explorer l'impact de la fréquence d'échantillonnage. → <https://doi.org/10.1038/s41597-019-0212-5>

Toolkit d'accès unifié

NILMTK (Non-Intrusive Load Monitoring Toolkit) Librairie Python qui unifie l'accès à la plupart des datasets ci-dessus, avec des outils de prétraitement, de conversion de format et de benchmarking. Point d'entrée recommandé pour commencer. → <https://github.com/nilmtn/nilmtn> → Paper : Batra et al. (2014) - <https://arxiv.org/abs/1404.3878>

NILMTK-contrib Extension de NILMTK avec des algorithmes récents implémentés de façon standardisée. Permet de lancer des comparaisons sur une base commune. → <https://github.com/nilmtn/nilmtn-contrib>

Une question à se poser sur les données

Les datasets académiques sont à 1 Hz ou plus. Le compteur Linky standard fournit des données à 30 minutes. Que se passe-t-il quand on dégrade la résolution temporelle ? Certains appareils restent-ils détectables ? C'est une question pratique directement liée au déploiement réel - et une étude d'ablation qui a de la valeur.

Pistes de modélisation - orientations, pas solutions

Prétraitement et feature engineering

Avant tout modèle, quelques questions à trancher :

- À quelle résolution temporelle travaille-t-on ? Faut-il rééchantillonner ?
- Comment gérer les valeurs manquantes et les artefacts de mesure ?
- Quelle taille de fenêtre glissante pour créer les séquences d'entrée ?
- Faut-il normaliser par appareil, par foyer, globalement ?

Ces choix ont un impact fort sur les résultats - les documenter fait partie du travail scientifique.

Approches de désagrégation à explorer

Deux grandes familles, avec des hypothèses très différentes :

Approches probabilistes et combinatoires Modélisent explicitement les états discrets de chaque appareil (ON/OFF ou multi-états) et cherchent la combinaison d'états la plus vraisemblable étant donné le signal agrégé observé.

→ **CO (Combinatorial Optimization)** - baseline exhaustive, référence théorique Implémenté dans NILMTK. Utile pour comprendre la structure du problème.

→ **FHMM (Factorial Hidden Markov Model)** - modèle probabiliste classique du domaine Kolter & Johnson (2011) - <http://redd.csail.mit.edu/kolter-kddsust11.pdf> Implémenté dans NILMTK.

→ **HMM par appareil** - un HMM indépendant par appareil, plus simple mais moins couplé → hmmlearn : <https://hmmlearn.readthedocs.io>

Approches deep learning Apprennent directement la relation entre le signal agrégé et la consommation d'un appareil cible, sans modélisation explicite des états.

→ **Seq2Point** - réseau convolutif 1D qui prédit la puissance d'un appareil au point central d'une fenêtre. Architecture de référence dans la littérature depuis 2018. Zhang et al. (2018) - <https://arxiv.org/abs/1612.09106> Implémentation de référence : <https://github.com/MingjunZhong/seq2point-nilm>

→ **Seq2Seq** - variante qui prédit toute la séquence de sortie plutôt que le point central. Même paper que Seq2Point - <https://arxiv.org/abs/1612.09106>

→ **BERT4NILM** - adaptation de l'architecture Transformer au problème de désagrégation. État de l'art récent. Yue et al. (2020) - <https://dl.acm.org/doi/10.1145/3427771.3429390> → <https://github.com/Yuezero/BERT4NILM>

→ **UNet-NILM** - architecture encoder-decoder de type U-Net adaptée au NILM. Multi-tâche : prédit simultanément la puissance et l'état ON/OFF. Faustine et al. (2021) - <https://arxiv.org/abs/2104.10407>

→ **LSTM / GRU** - réseaux récurrents, point de passage naturel entre les approches séquentielles et les transformers. À implémenter comme intermédiaire de comparaison. → pytorch ou keras selon votre préférence

Protocole d'évaluation - point critique

C'est un des problèmes récurrents de la littérature NILM : les comparaisons sont souvent faites sur des protocoles incompatibles, ce qui rend les résultats non comparables entre papiers.

Quelques décisions à prendre et à documenter explicitement :

Train / test split : Entraîner sur les maisons A, B, C et tester sur D et E - pas sur les mêmes maisons. C'est le seul protocole honnête pour mesurer la généralisation inter-foyers, qui est l'enjeu industriel réel.

Par appareil ou multi-appareils : La plupart des approches deep learning entraînent un modèle par appareil cible. Est-ce scalable ? Y a-t-il un intérêt à un modèle multi-appareils partagé ?

Métriques : Plusieurs métriques coexistent dans la littérature - MAE sur la puissance, F1-score sur l'état ON/OFF, erreur sur l'énergie totale reconstituée. Elles ne mesurent pas la même chose. Laquelle est la plus pertinente pour votre objectif opérationnel ?

→ Nalmpantis & Vrakas (2019), *Machine learning approaches for NILM: A benchmark* - <https://doi.org/10.1007/s10618-019-00621-x> → Batra et al. (2019), *Towards reproducible state-of-the-art energy disaggregation* - <https://arxiv.org/abs/1901.02940>

De la désagrégation à la flexibilité énergétique

C'est la valeur ajoutée du projet au-delà de la désagrégation pure. Une fois qu'on sait quand tourne chaque appareil, peut-on estimer la flexibilité disponible dans un foyer ?

Quelques pistes à explorer :

- Quels appareils sont intrinsèquement flexibles - leur cycle peut être décalé sans impact sur le confort ?
- Comment définir une fenêtre de flexibilité pour un appareil donné - amplitude, durée, contraintes ?
- Comment agréger la flexibilité individuelle à l'échelle d'un quartier ou d'une zone ?

C'est une question ouverte - la littérature sur la flexibilité résidentielle est moins mature que celle sur la désagrégation. C'est là que peut se situer une contribution originale.

→ Lecture utile : Palensky & Dietrich (2011), *Demand side management: Demand response, intelligent energy systems, and smart loads* - <https://doi.org/10.1109/TII.2011.2158841> → Une revue récente sur la flexibilité résidentielle : Lopes et al. (2016) - <https://doi.org/10.1016/j.rser.2016.01.041>

Lectures de référence

Article fondateur du NILM : Hart, G.W. (1992). *Nonintrusive appliance load monitoring*. Proceedings of the IEEE. → <https://doi.org/10.1109/5.192069>

Premier dataset de référence et formulation probabiliste : Kolter, J.Z. & Johnson, M.J. (2011). *REDD: A public data set for energy disaggregation research*. → <http://redd.csail.mit.edu/kolter-kddust11.pdf>

Premier article deep learning en NILM : Kelly, J. & Knottenbelt, W. (2015). *Neural NILM: Deep neural networks applied to energy disaggregation*.

Seq2Point - architecture de référence : Zhang, C. et al. (2018). *Sequence-to-point learning with neural networks for non-intrusive load monitoring*. AAAI. → <https://arxiv.org/abs/1612.09106>

BERT4NILM - état de l'art transformer : Yue, Z. et al. (2020). *BERT4NILM: A bidirectional transformer model for NILM*. ACM e-Energy. → <https://dl.acm.org/doi/10.1145/3427771.3429390>

Benchmark comparatif - lecture structurante : Nalmpantis & Vrakas (2019). *Machine learning approaches for NILM: A benchmark*

Reproductibilité et protocoles d'évaluation : Batra et al. (2019). *Towards reproducible state-of-the-art energy disaggregation*.

Librairies et outils

nilmtk # accès unifié aux datasets, prétraitement, benchmarks

<https://github.com/nilmtk/nilmtk>

nilmtk-contrib # algorithmes récents intégrés dans NILMTK

<https://github.com/nilmtk/nilmtk-contrib>

pytorch / keras # implémentation des modèles deep learning

<https://pytorch.org> <https://keras.io>

hmmlearn # Hidden Markov Models

<https://hmmlearn.readthedocs.io>

tslearn # outils pour séries temporelles

<https://tslearn.readthedocs.io>

scikit-learn # métriques, prétraitement

<https://scikit-learn.org>

pandas / numpy # manipulation des données

matplotlib / plotly # visualisation des signaux et résultats